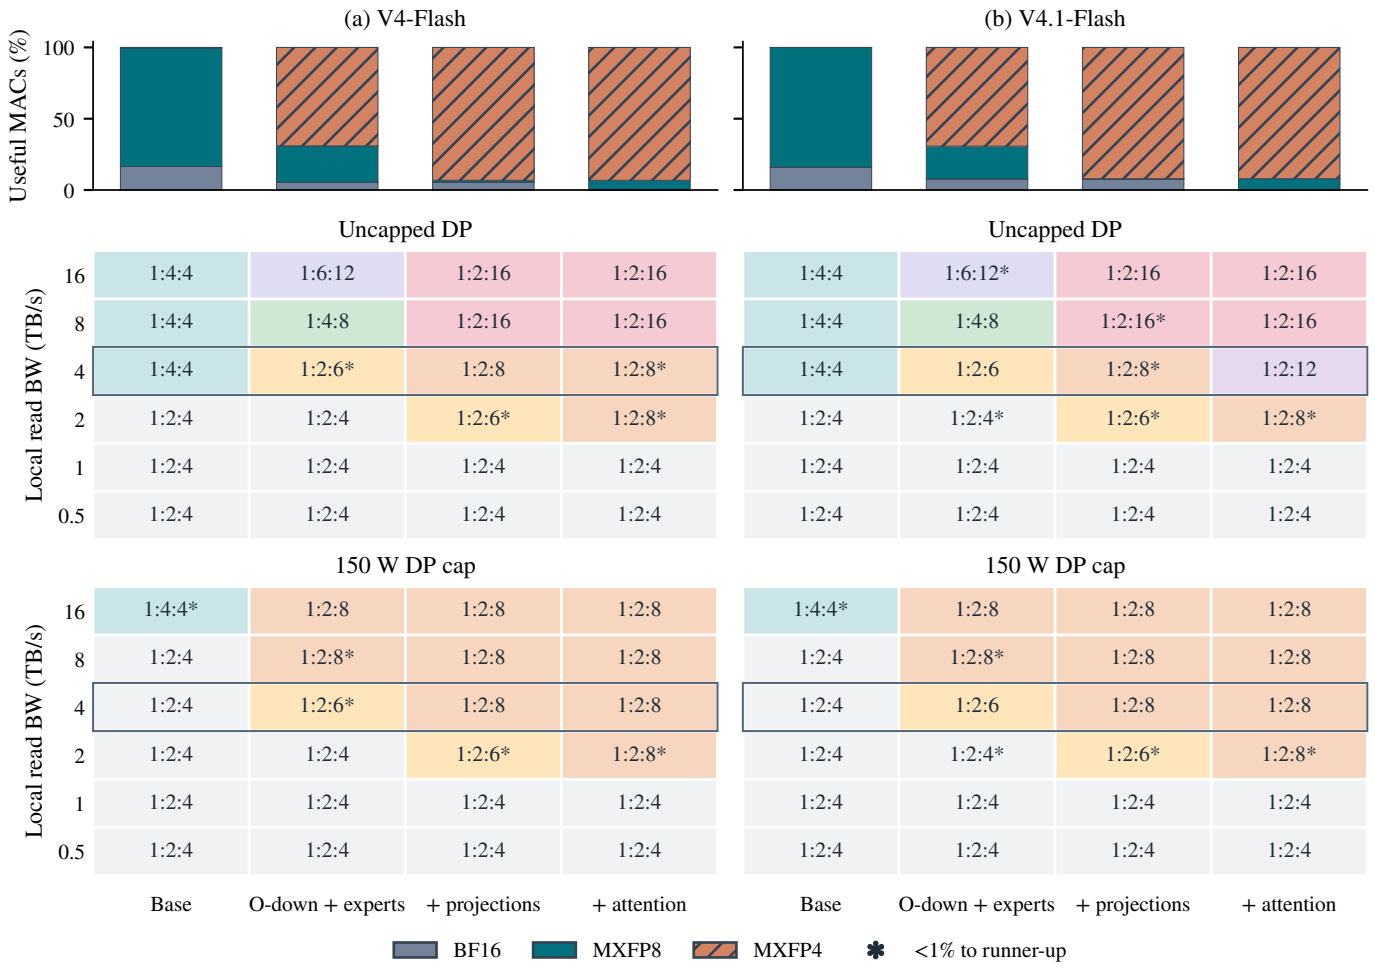
(a) V4-Flash
(b) V4.1-Flash
Useful MACs (%)
100
50
0
Uncapped DP
Local read BW (TB/s)
16 1:4:4 1:6:12 1:2:16 1:2:16
8 1:4:4 1:4:8 1:2:16 1:2:16
4 1:4:4 1:2:6* 1:2:8 1:2:8*
2 1:2:4 1:2:4 1:2:6* 1:2:8*
1 1:2:4 1:2:4 1:2:4 1:2:4
0.5 1:2:4 1:2:4 1:2:4 1:2:4
Uncapped DP
16 1:4:4 1:6:12* 1:2:16 1:2:16
8 1:4:4 1:4:8 1:2:16* 1:2:16
4 1:4:4 1:2:6 1:2:8* 1:2:12
2 1:2:4 1:2:4* 1:2:6* 1:2:8*
1 1:2:4 1:2:4 1:2:4 1:2:4
0.5 1:2:4 1:2:4 1:2:4 1:2:4
150 W DP cap
Local read BW (TB/s)
16 1:4:4* 1:2:8 1:2:8 1:2:8
8 1:2:4 1:2:8* 1:2:8 1:2:8
4 1:2:4 1:2:6* 1:2:8 1:2:8
2 1:2:4 1:2:4 1:2:6* 1:2:8*
1 1:2:4 1:2:4 1:2:4 1:2:4
0.5 1:2:4 1:2:4 1:2:4 1:2:4
150 W DP cap
16 1:4:4* 1:2:8 1:2:8 1:2:8
8 1:2:4 1:2:8* 1:2:8 1:2:8
4 1:2:4 1:2:6 1:2:8 1:2:8
2 1:2:4 1:2:4* 1:2:6* 1:2:8*
1 1:2:4 1:2:4 1:2:4 1:2:4
0.5 1:2:4 1:2:4 1:2:4 1:2:4
Base
O-down + experts
+ projections
+ attention
Base
O-down + experts
+ projections
+ attention
BF16
MXFP8
MXFP4
✱ <1% to runner-up